Проект по анализу данных

...

Астафьев Никита (БПИ-242)
Брыкин Егор (БПИ-242)

Веб Скрейпер

•••

Steam hardware survey

ITEM	MOST POPULAR	PERCENTAGE	CHANGE
OS Version	Windows 11 64 bit	66.71%	+0.11%
System RAM	16 GB	40.24%	-0.53%
Intel CPU Speeds	2.3 Ghz to 2.69 Ghz	20.89%	+0.71%
Physical CPUs	6 cpus	28.45%	+0.17%
Video Card Description	NVIDIA GeForce RTX 4060	4.16%	+0.46%
VRAM	8 GB	29.57%	-3.11%
Primary Display Resolution	1920 x 1080	52.59%	+0.01%
Multi-Monitor Desktop Resolution	3840 x 1080	50.14%	0.00%
Language	English	37.01%	-2.21%
Free Hard Drive Space	100 GB to 249 GB	22.59%	+0.19%
Total Hard Drive Space	Above 1 TB	52.33%	+1.81%
VR Headsets	Meta Quest 3	28.17%	+0.36%
Other Settings	LAHF / SAHF	98.49%	-0.10%

Steam hardware survey 2026

January 2026 (click line item to see more detail)

ITEM	MOST POPULAR	PERCENTAGE	CHANGE
OS Version	Windows 11 64 bit	66.71%	+0.11%
System RAM	16 GB	40.24%	-0.53%
Intel CPU Speeds	2.3 Ghz to 2.69 Ghz	20.89%	+0.71%
Physical CPUs	6 cpus	28.45%	+0.17%
Video Card Description	NVIDIA GeForce RTX 4060	4.16%	+0.46%
VRAM	8 GB	29.57%	-3.11%
Primary Display Resolution	1920 x 1080	52.59%	+0.01%
Multi-Monitor Desktop Resolution	3840 x 1080	50.14%	0.00%
Language	English	37.01%	-2.21%
Free Hard Drive Space	100 GB to 249 GB	22.59%	+0.19%
Total Hard Drive Space	Above 1 TB	52.33%	+1.81%
VR Headsets	Meta Quest 3	28.17%	+0.36%
Other Settings	LAHF / SAHF	98.49%	-0.10%

Steam hardware survey 2008

November 2008 (click line item to see more detail)

Data	Most Popular	Percentage
Windows Version	Windows XP 32 bit	68.67%
System RAM	2.0 Gb and above	56.18%
Processor Vendor	GenuineIntel	64.24%
Intel CPU Speeds	2.3 Ghz to 2.69 Ghz	20.00%
AMD CPU Speeds	2.0 Ghz to 2.29 Ghz	13.43%
Physical CPUs	2 cpus	49.27%
DirectX 10 Systems (Vista with DirectX 10 GPU)	NVIDIA GeForce 8800	5.30%
DirectX 10 GPUs	NVIDIA GeForce 8800	27.05%
DirectX 9 Shader Model 2b and 3.0 GPUs	NVIDIA GeForce 7600	13.94%
DirectX 9 Shader Model 2.0 GPUs	ATI Radeon 9600	17.10%
MSAA Support Level	4x	87.17%
NVIDIA Drivers	6.14.11.7824 (10/7/2008)	8.87%
ATI Drivers	6.14.10.6869 (9/24/2008)	7.66%
Video Card Driver Name	nv4_disp.dll	43.28%
Video Card Description	NVIDIA GeForce 8800	12.43%
Multi-GPU Systems	NVIDIA SLI (2 GPUs)	1.55%
VRAM	512 MB	32.82%
Primary Display Resolution	1024 x 768	25.42%
Multi-Monitor Desktop Resolution	2560 x 1024	16.30%
4:3 Displays Physical Size	16"	22.89%
16:9 Displays Physical Size	27"	17.90%
Audio Devices	Realtek HD Audio output	20.66%
Microphones	Yes	64.73%
Language	English	59.88%
Drive Type	DVD	96.15%
Free Hard Drive Space	10 GB to 99 GB	48.04%
Total Hard Drive Space	100 GB to 249 GB	39.64%
Network Speed	2,048.0 Kbps	29.38%
Other Settings	FCMOV	99.99%

Потенциальные проблемы

Комплектующие для ПК и технологии не стоят на месте:

1. Не все данные, доступные в 2008 году, собираются в 2026.
2. Категории менялись вместе с характеристиками ПК.
3. Единицы измерения менялись со временем.
4. Steam hardware survey не предоставляет исторические данные...

Источник данных

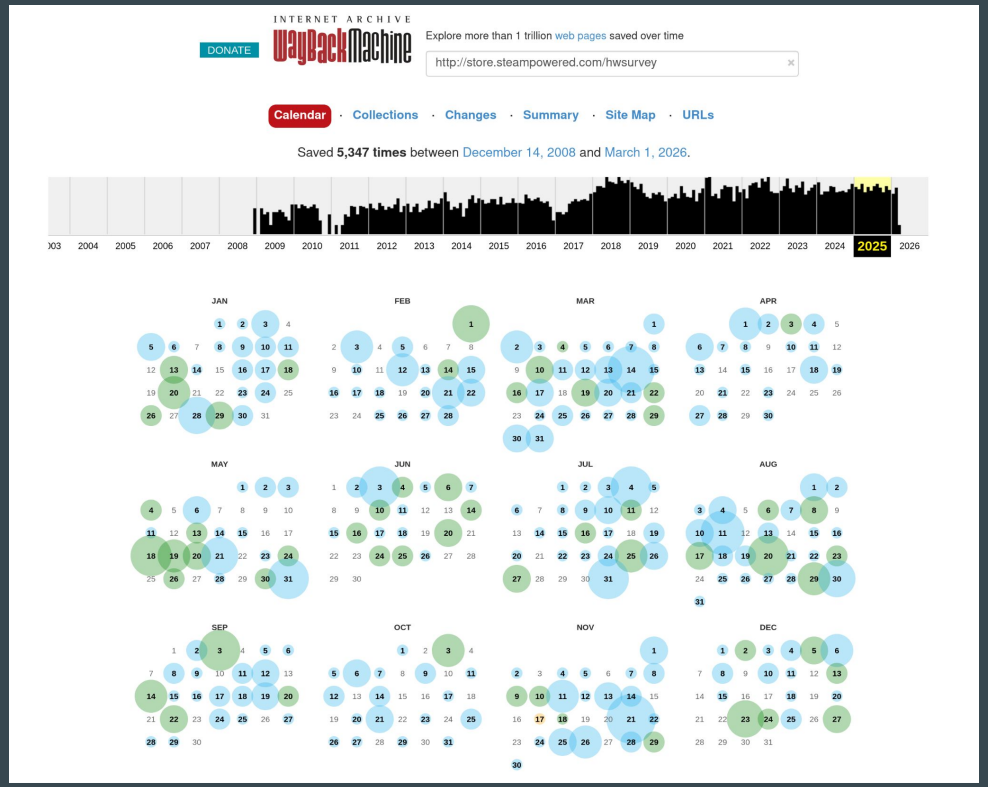

Работа скрейпера

Действия скрейпера кэшируются на диске. Все запуски кроме первого **не будут** делать запросов в сеть интернет.

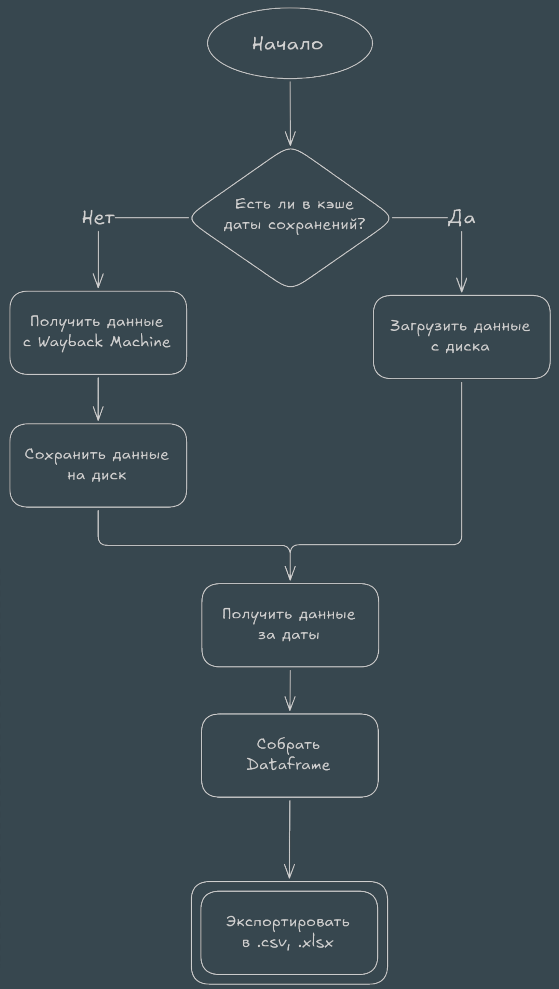

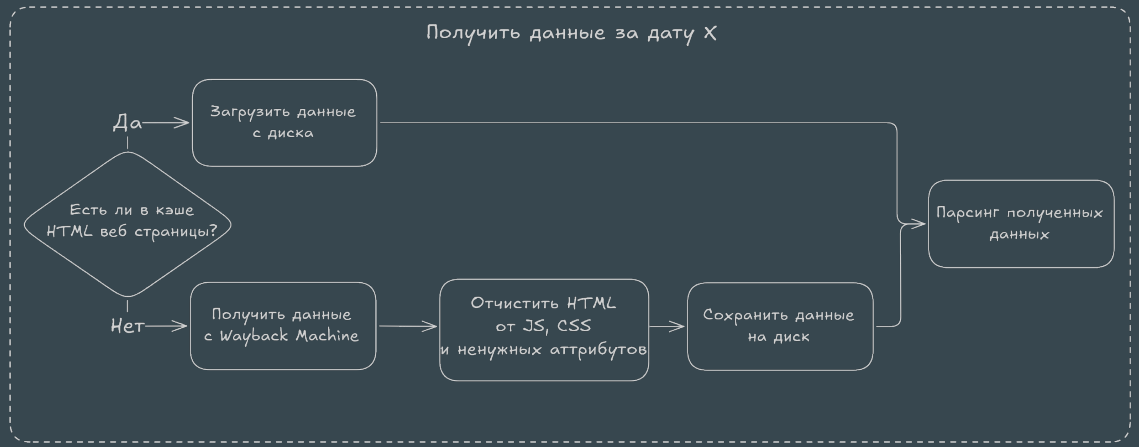

Датасет и интересные факты

1. 2387 строк (211 уникальных)
2. 20+ переменных

3. Посещено 2566+ веб страниц
4. Сохранено 302 MB HTML
5. Новый датасет генерируется за 80 секунд*

* Процессор Ultra 5 225h @ 4.9GHz, прогретый кэш.

Итоги

Исходный код

Датасет

Анализ данных

...

Датасет: Telco Customer Churn

- более 7000 записей и 21 столбец

Данные:

- Демография: пол, возраст (пенсионер/нет), наличие партнера и иждивенцев.
- Услуги клиента: телефония, интернет (DSL/Fiber optic), потоковое ТВ, защита устройств и т.д.
- Финансы: тип контракта, способ оплаты, ежемесячные и общие платежи.
- Целевая переменная: Churn (ушел ли клиент из компании за последний месяц).

Предобработка данных

- Перекодированы переменные (No/Yes → 0/1)
- Приведение типов
- Убраны 11 (≈ 0.16%) пропусков

Познакомимся с данными

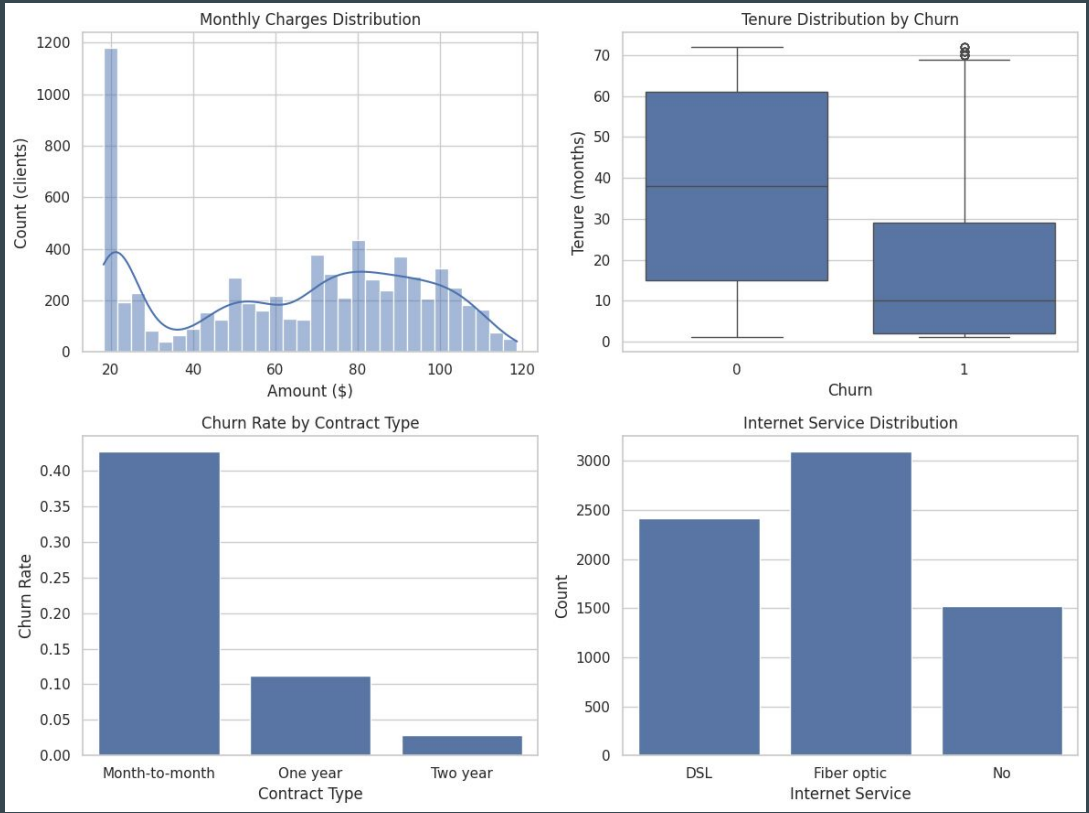

Познакомимся с данными

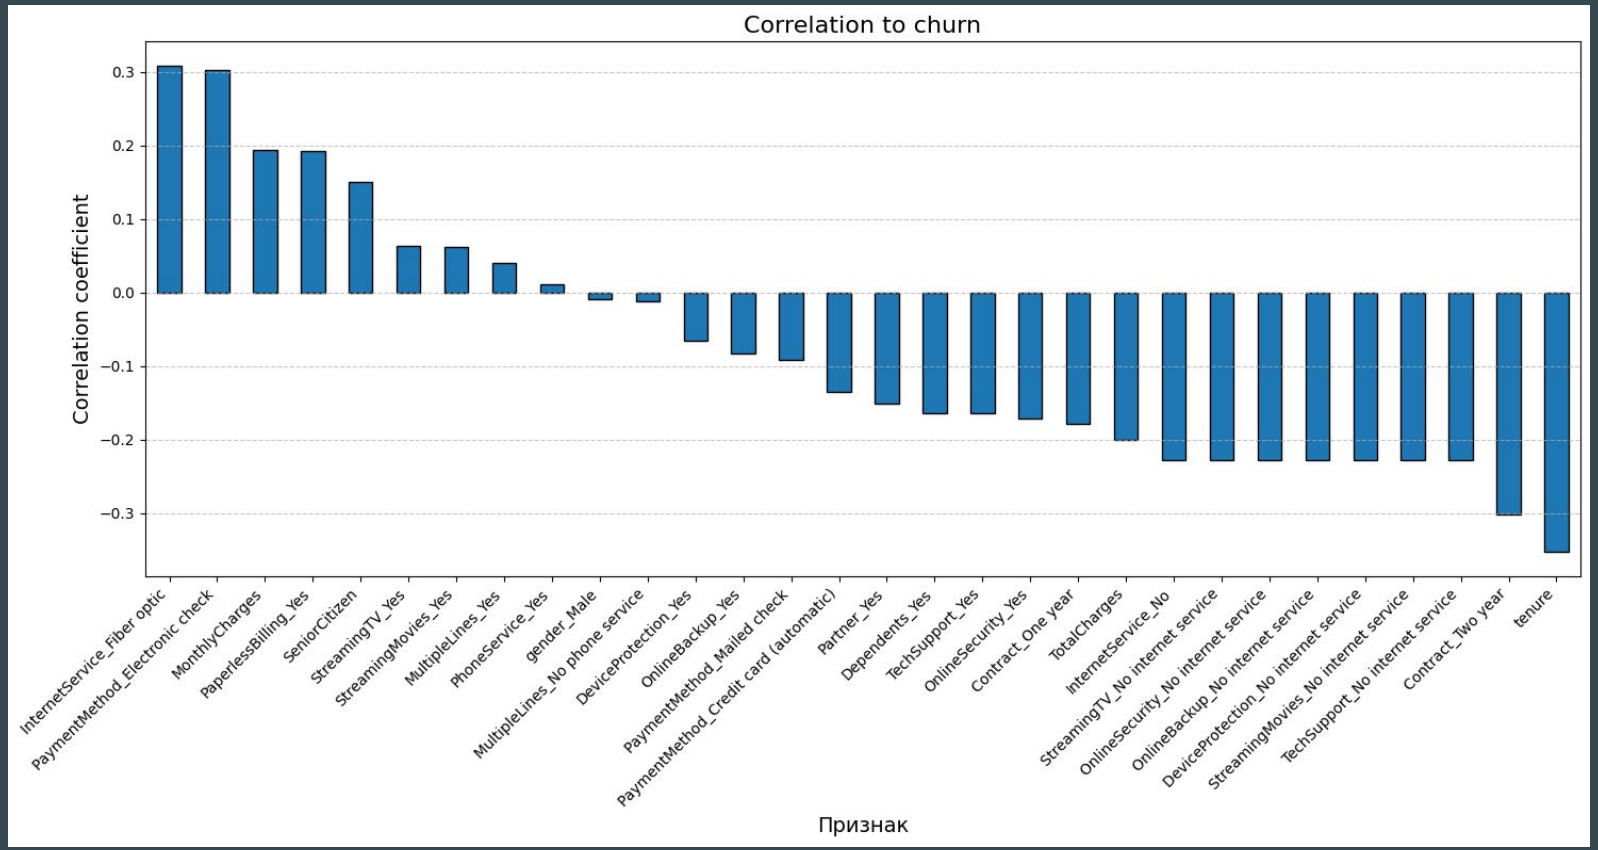

Познакомимся с данными

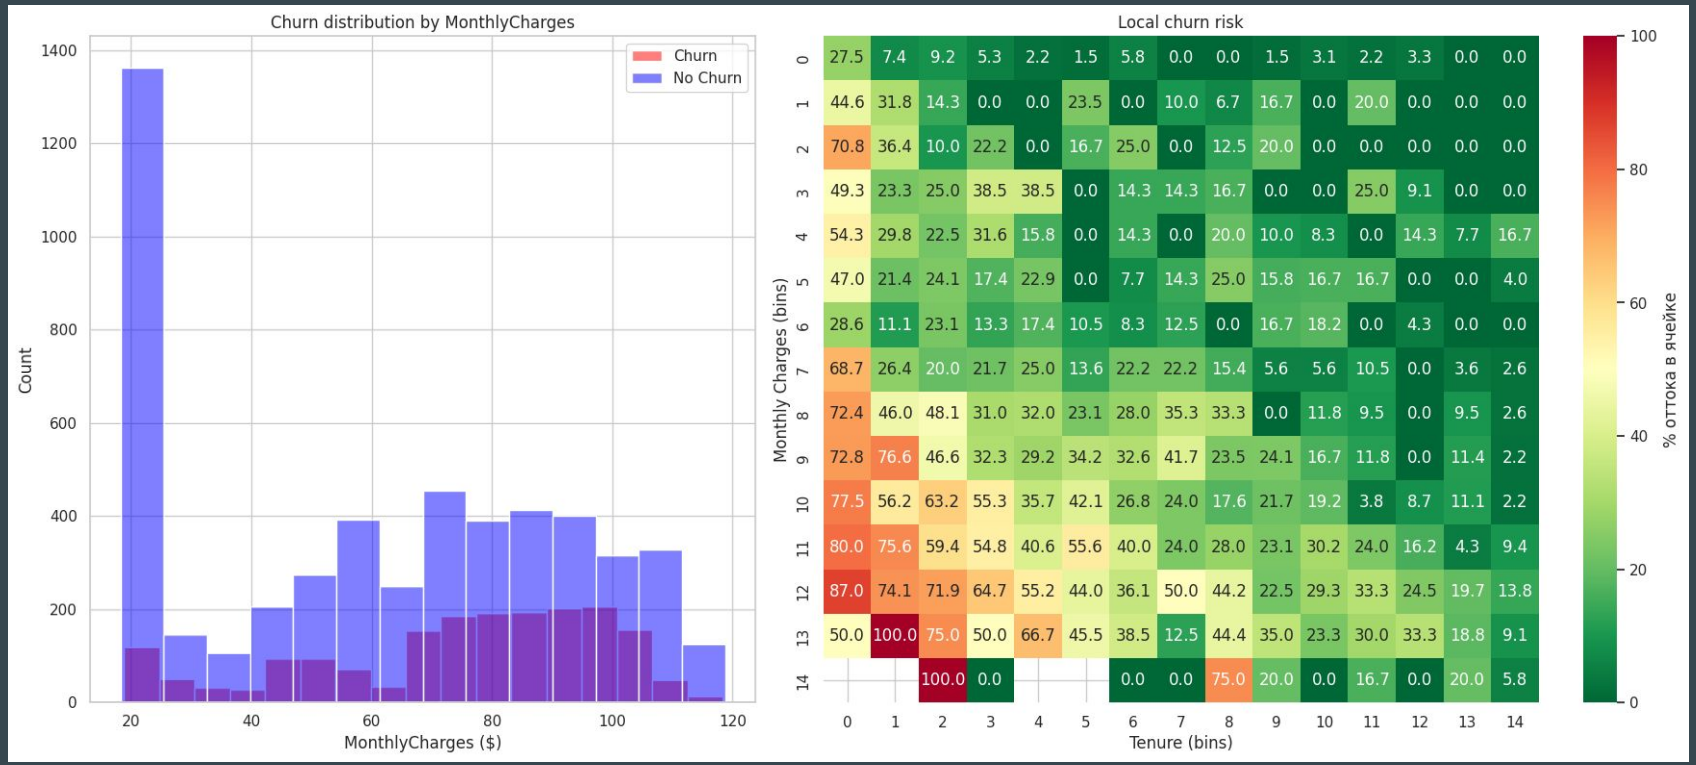

Гипотезы:

№	Гипотеза
1	Клиенты с помесечным контрактом (`Contract` = Month-to-month) уходят чаще.
2	Наличие оптоволокна (`InternetService` = Fiber optic) повышает риск оттока.
3	Клиенты старше 65 лет (`SeniorCitizen` = 1) уходят реже.
4	Высокая ежемесячная плата (`MonthlyCharges`) коррелирует с оттоком.
5	Клиенты без технической поддержки (`TechSupport` = No) уходят чаще.
6	Способ оплаты электронным чеком (`PaymentMethod` = Electronic check) связан с высоким оттоком.
7	Клиенты с партнером (`Partner` = Yes) или зависимыми (`Dependents` = Yes) уходят реже.
8	Чем дольше клиент с компанией (`tenure`), тем ниже риск оттока.
9	Наличие доп. услуг (`OnlineSecurity` = Yes и т.д.) снижает отток.
10	`tenure` и `MonthlyCharges` коррелируют (клиенты со стажем имеют другие тарифы)

Цели:

- Найти сильные факторы удержания
- Выяснить почему уходят клиенты

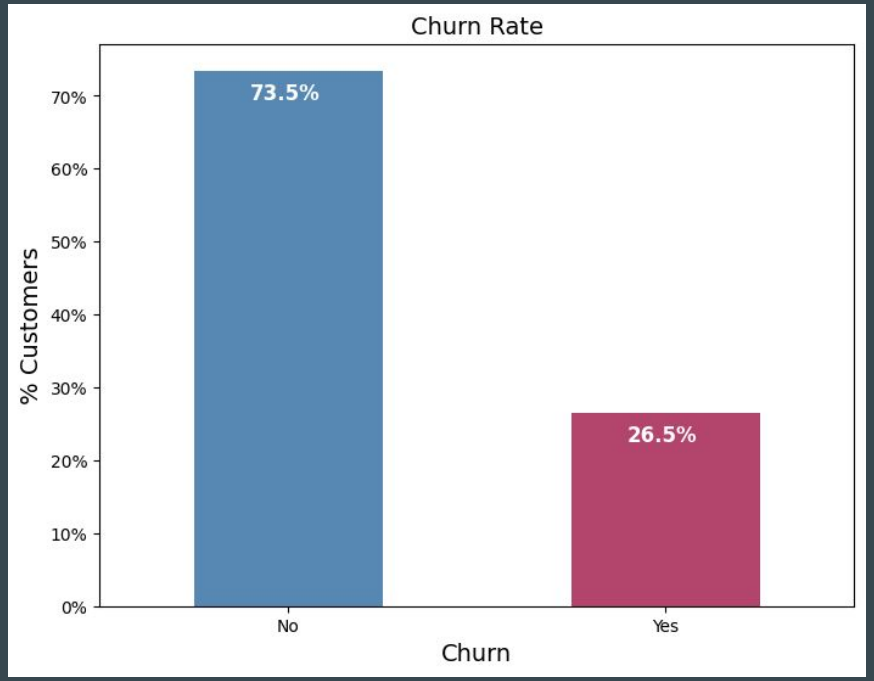

Действия:

Самые сильные факторы удержания:

- Бинарная и линейная регрессии

Профиль ушедшего клиента:

- Кластеризация

Бинарная регрессия

Целевая переменная - Churn (ушел клиент или нет)

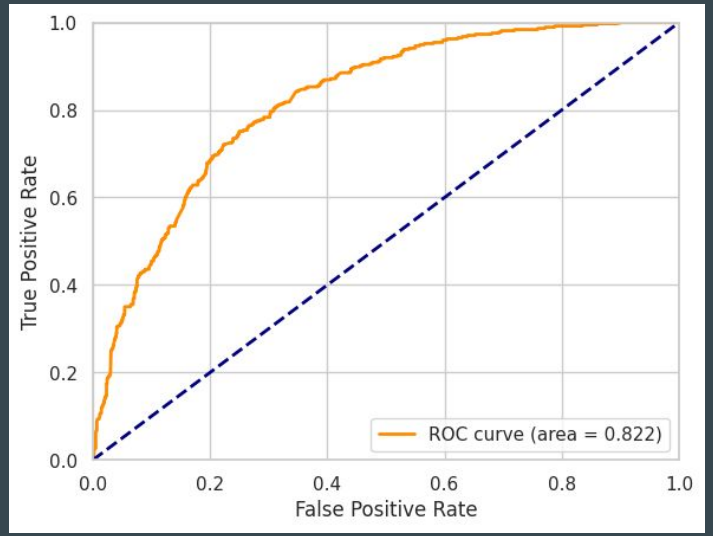

Max VIF < 5
Pseudo R^2 = 0.279

Модель лучше случайного угадывания на 32% (AUC-ROC = 0.822)

Бинарная регрессия

Целевая переменная - Churn (ушел клиент или нет)

Fiber Optic	+0.96	**2.6x**
One Year Contract	-0.90	**0.4x**
Two Year Contract	-1.48	**0.2x**
Tech Support	-0.45	**0.6x**
Tenure	-0.03	**0.97x**

Линейная регрессия

Целевая переменная - tenue (срок жизни клиента)

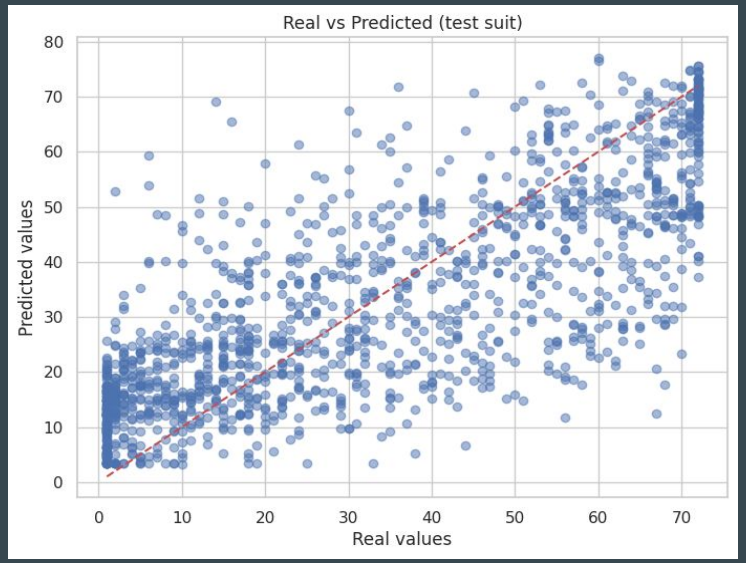

Max VIF < 5
R^2 (train/test) = 0.605/0.603
MAE = 1 год

Модель объясняет 60% вариации срока жизни клиента

Линейная регрессия

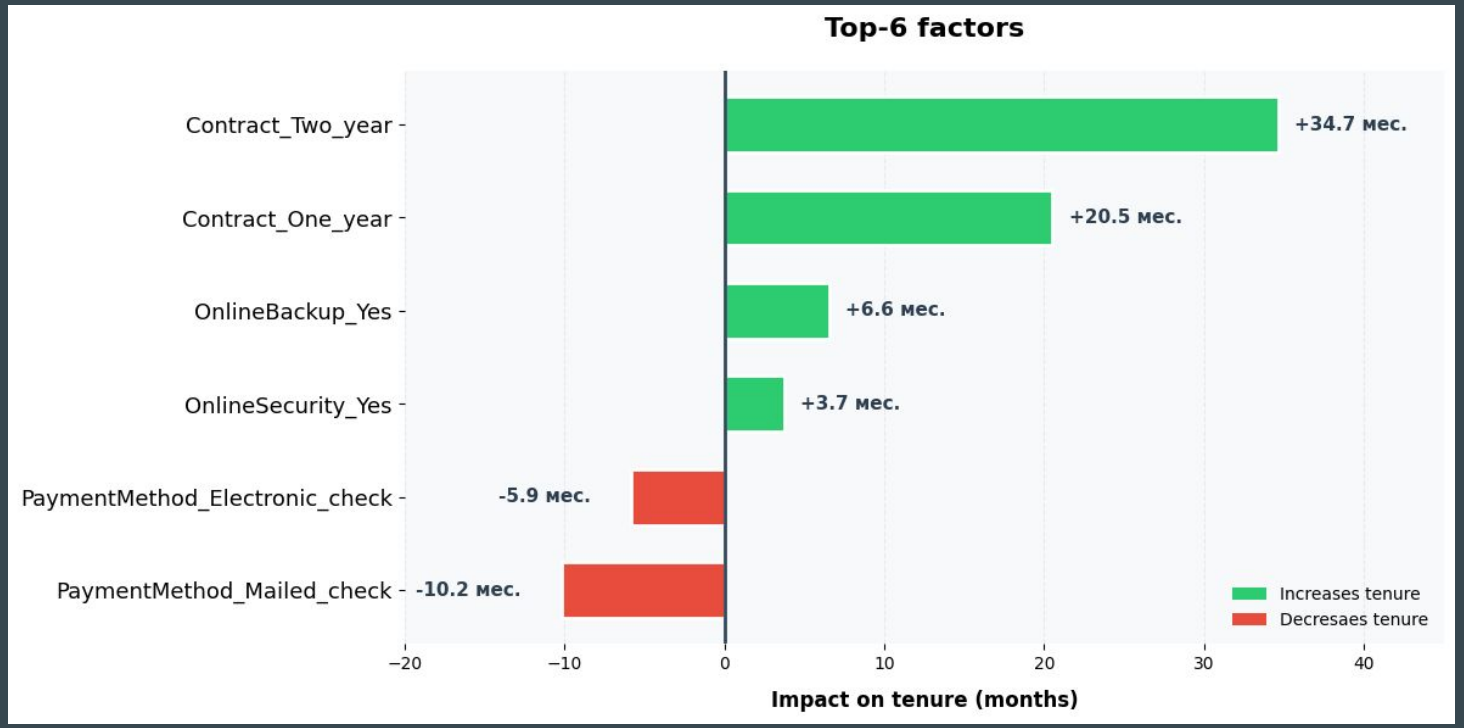

Кластеризация

Сгруппируем ушедших клиентов по причине ухода

Посмотрим на данные с разных перспектив:

- K-Prototypes* - форма
- DBSCAN - плотность

*Рассматриваются как метрические, так и категориальные переменные

Кластеризация K-Prototypes

Возьмем количество кластеров K = 3

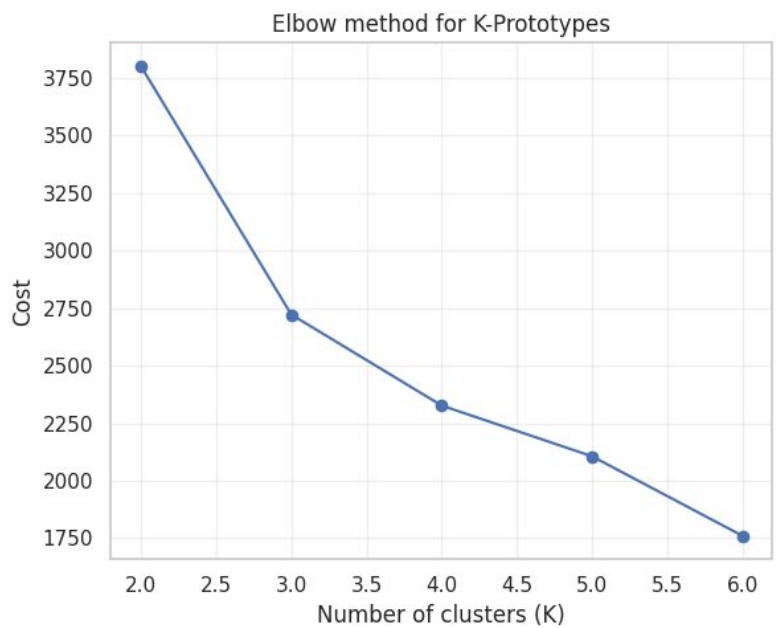

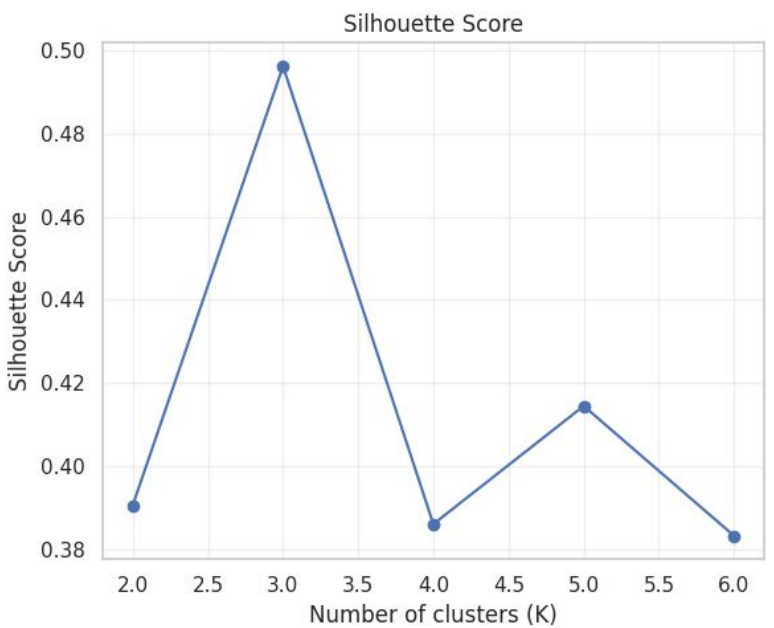

Кластеризация K-Prototypes

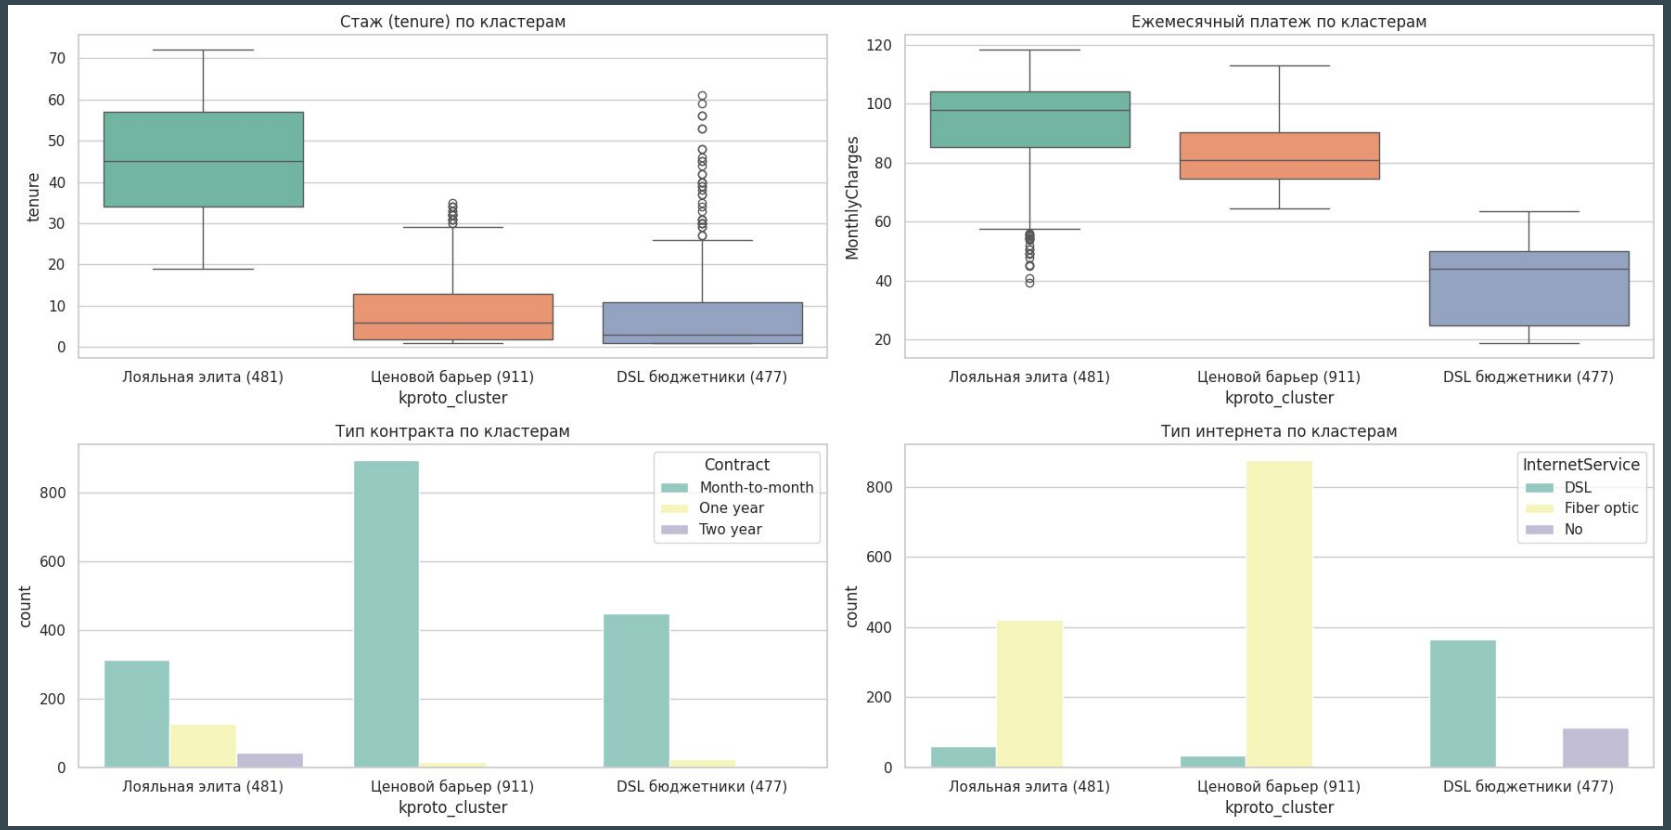

Кластеризация DBSCAN

Возьмем окрестность ε = 1.5

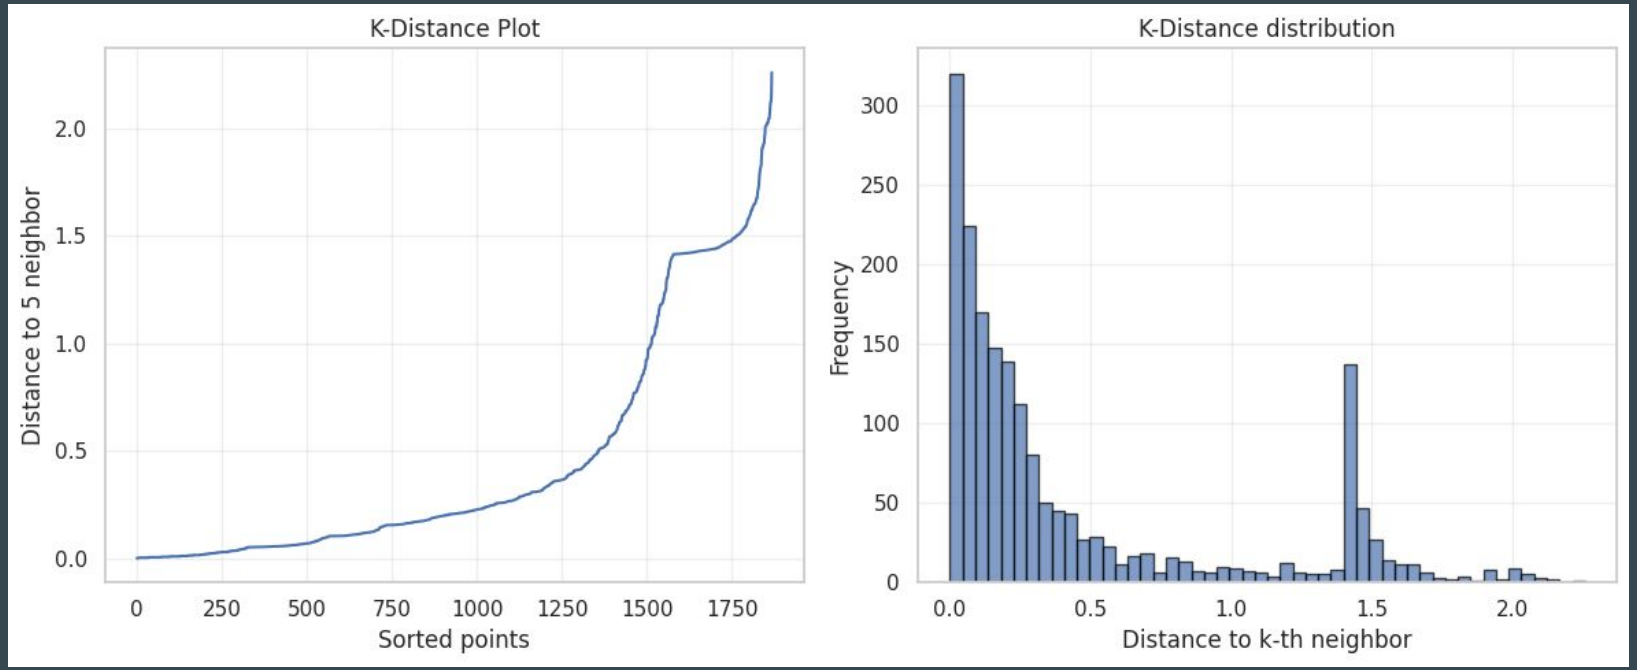

Кластеризация DBSCAN

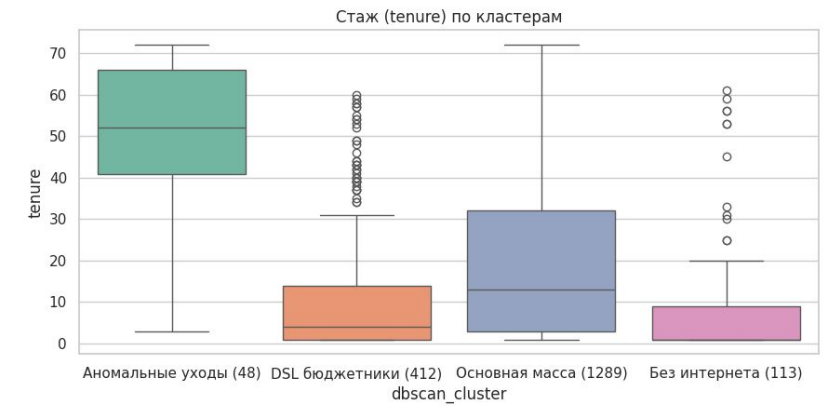

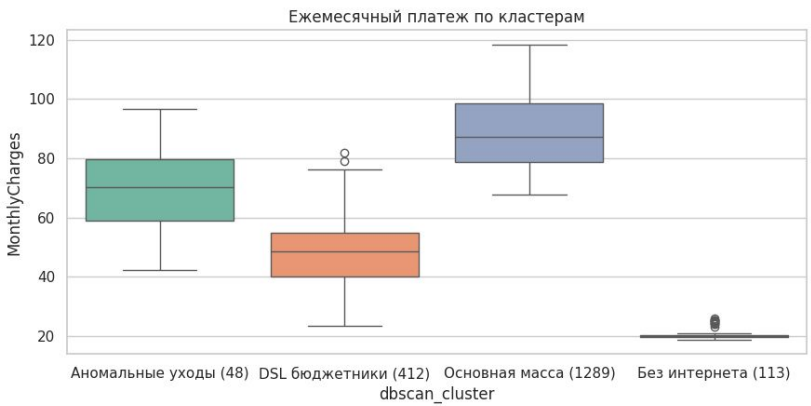

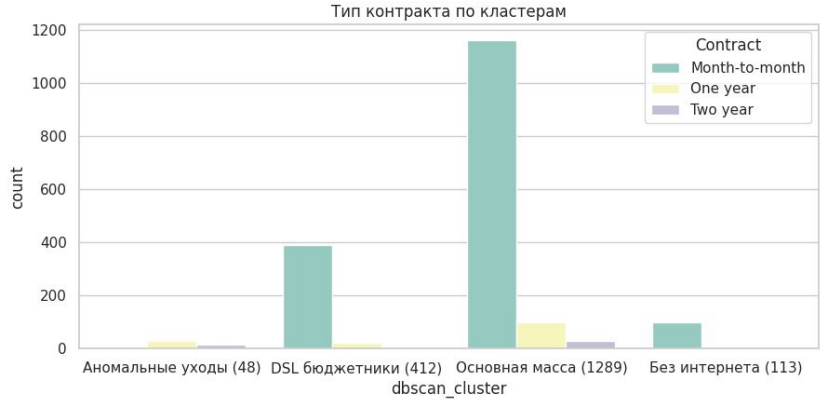

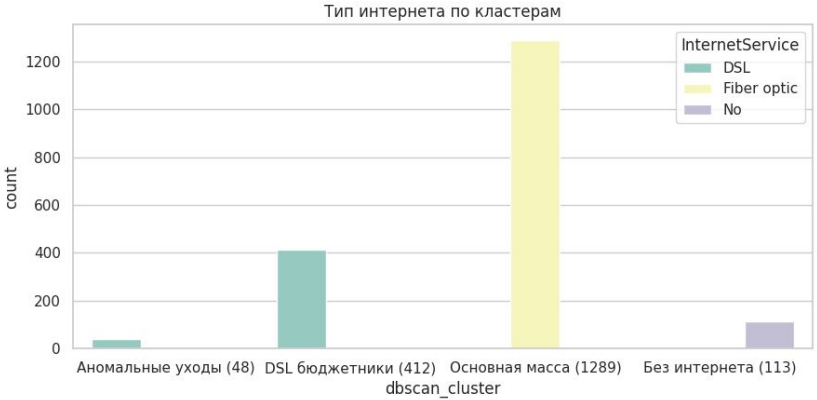

Интересные факты

1. Пенсионеры уходят чаще - гипотеза 3 опровергнута
2. Пользователи, которые пользуются оптоволокном массово уходят
3. Пользователи, подключившие стриминговые услуги уходят чаще - гипотеза 9 частично опровергнута

Спасибо за внимание!

Больше графиков

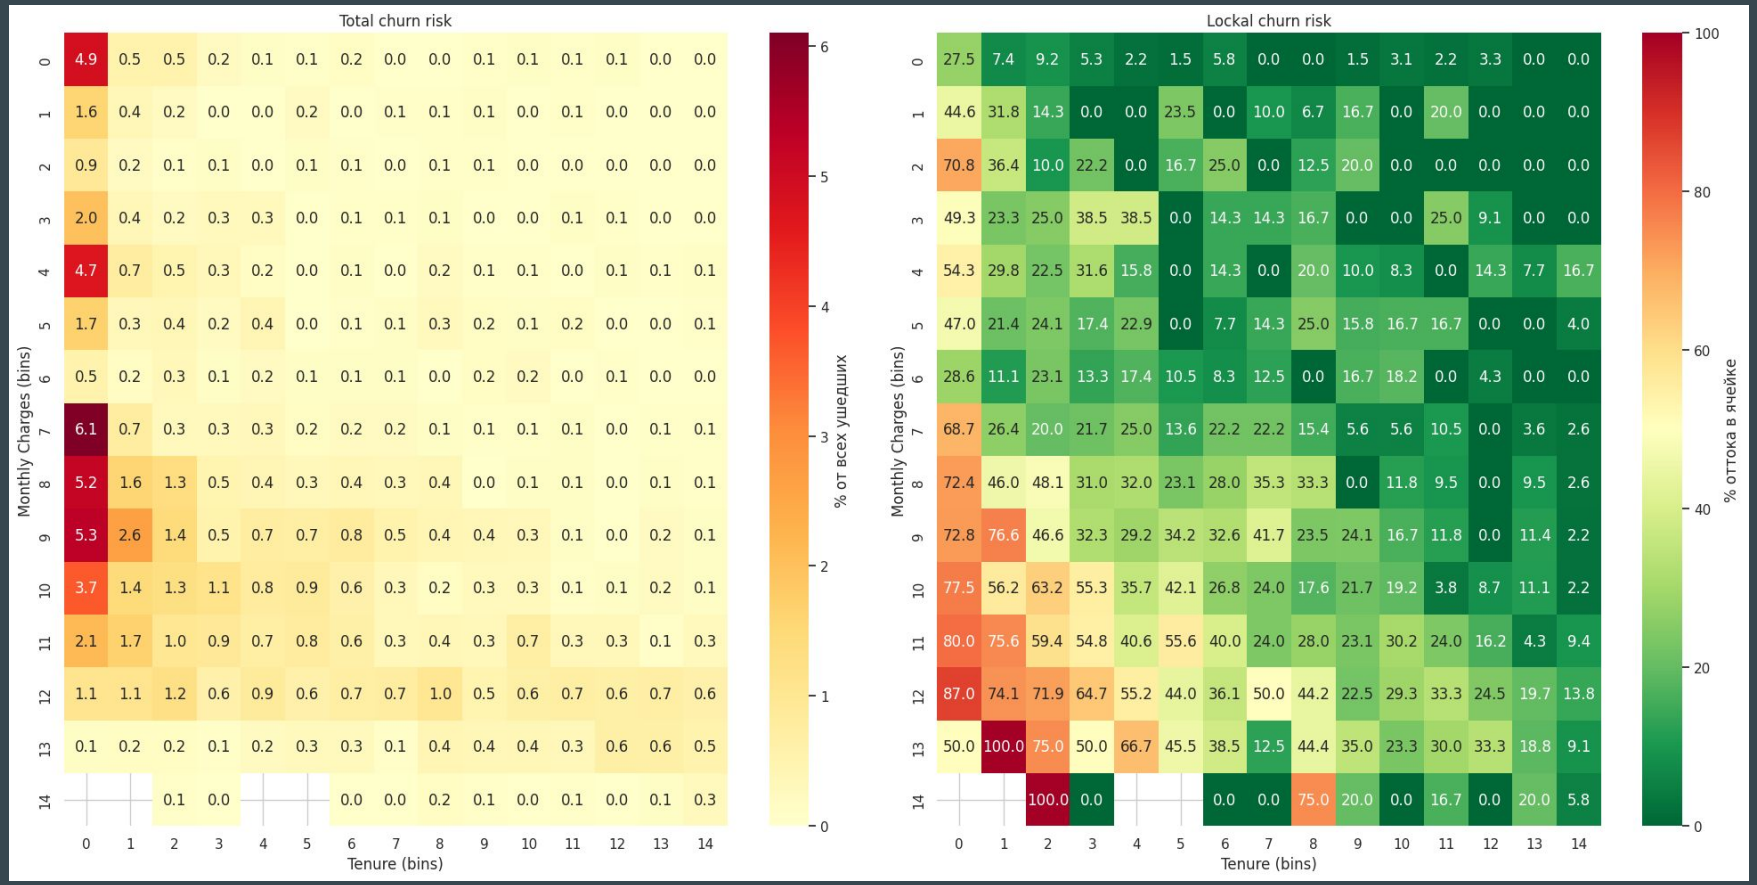
Total churn risk
Monthly Charges (bins)
Tenure (bins)
% от всех ушедших
Lockal churn risk
Monthly Charges (bins)
Tenure (bins)
% оттока в ячейке

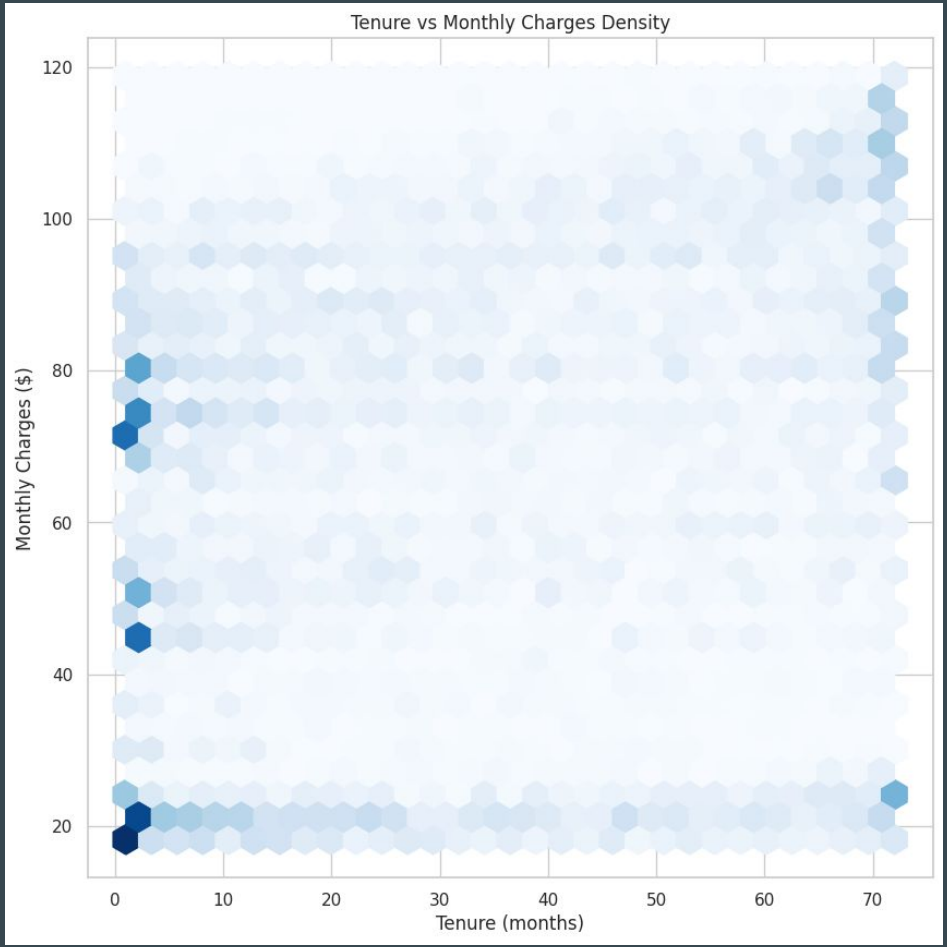
Tenure vs Monthly Charges Density
Monthly Charges ($)
120
100
80
60
40
20
0
10
20
30
40
50
60
70
Tenure (months)

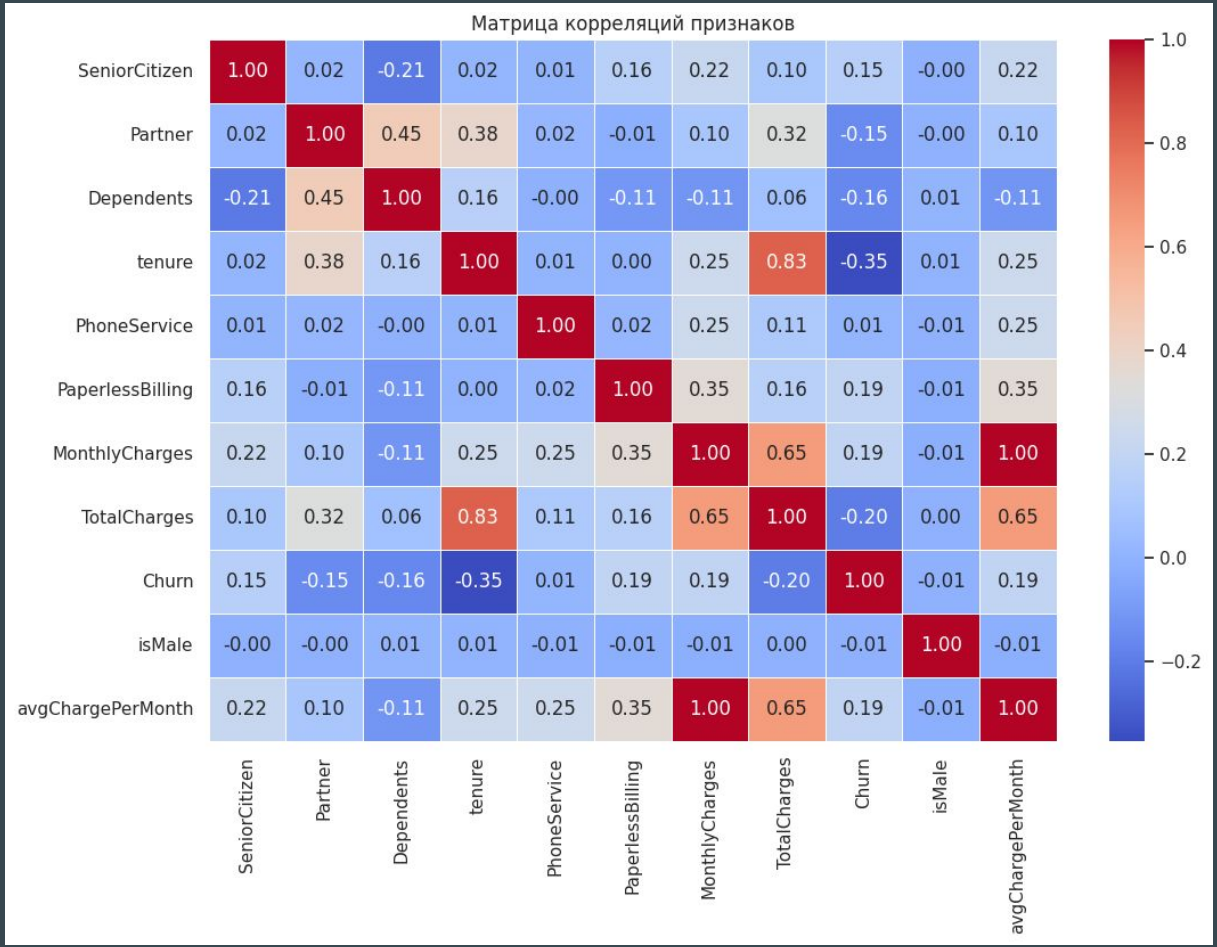
Матрица корреляций признаков
SeniorCitizen 1.00 0.02 -0.21 0.02 0.01 0.16 0.22 0.10 0.15 -0.00 0.22
Partner 0.02 1.00 0.45 0.38 0.02 -0.01 0.10 0.32 -0.15 -0.00 0.10
Dependents -0.21 0.45 1.00 0.16 -0.00 -0.11 -0.11 0.06 -0.16 0.01 -0.11
tenure 0.02 0.38 0.16 1.00 0.01 0.00 0.25 0.83 -0.35 0.01 0.25
PhoneService 0.01 0.02 -0.00 0.01 1.00 0.02 0.25 0.11 0.01 -0.01 0.25
PaperlessBilling 0.16 -0.01 -0.11 0.00 0.02 1.00 0.35 0.16 0.19 -0.01 0.35
MonthlyCharges 0.22 0.10 -0.11 0.25 0.25 0.35 1.00 0.65 0.19 -0.01 1.00
TotalCharges 0.10 0.32 0.06 0.83 0.11 0.16 0.65 1.00 -0.20 0.00 0.65
Churn 0.15 -0.15 -0.16 -0.35 0.01 0.19 0.19 -0.20 1.00 -0.01 0.19
isMale -0.00 -0.00 0.01 0.01 -0.01 -0.01 -0.01 0.00 -0.01 1.00 -0.01
avgChargePerMonth 0.22 0.10 -0.11 0.25 0.25 0.35 1.00 0.65 0.19 -0.01 1.00
SeniorCitizen
Partner
Dependents
tenure
PhoneService
PaperlessBilling
MonthlyCharges
TotalCharges
Churn
isMale
avgChargePerMonth
1.0
0.8
0.6
0.4
0.2
0.0
−0.2

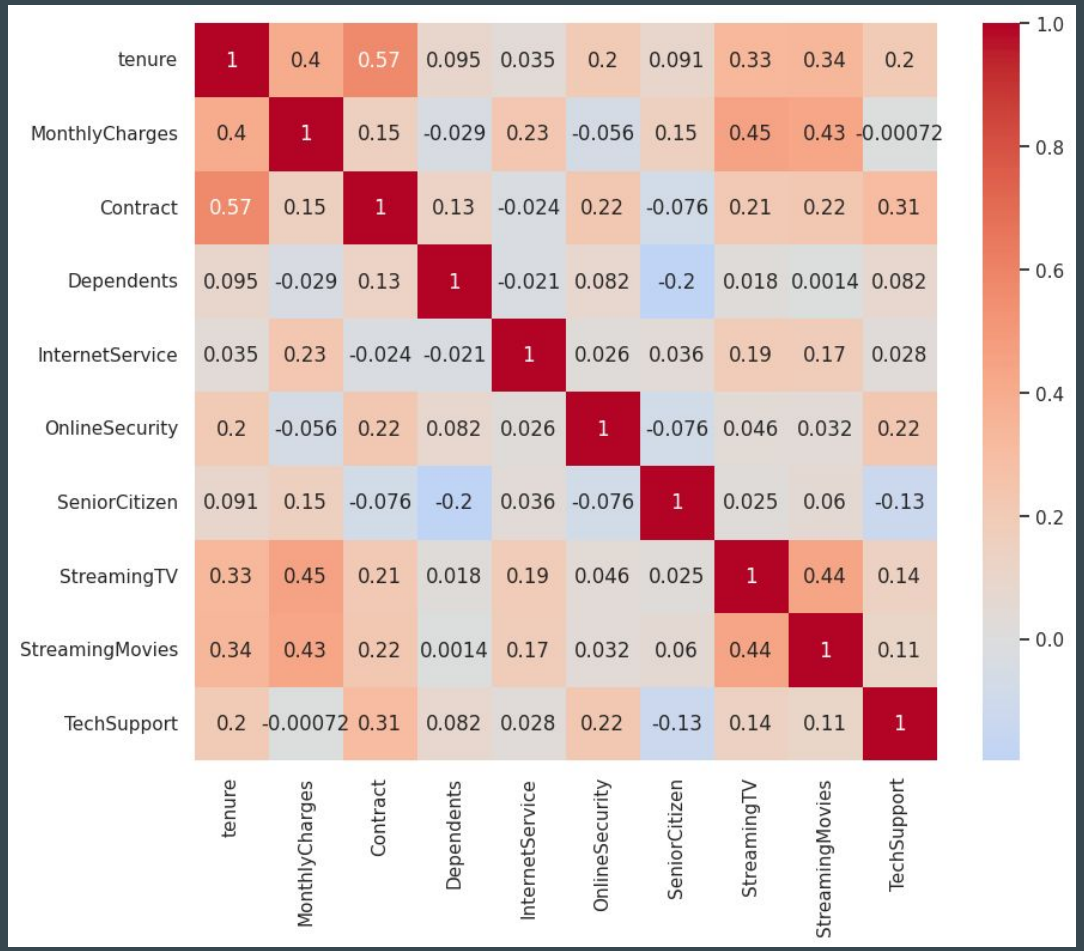
tenure 1 0.4 0.57 0.095 0.035 0.2 0.091 0.33 0.34 0.2
MonthlyCharges 0.4 1 0.15 -0.029 0.23 -0.056 0.15 0.45 0.43 -0.00072
Contract 0.57 0.15 1 0.13 -0.024 0.22 -0.076 0.21 0.22 0.31
Dependents 0.095 -0.029 0.13 1 -0.021 0.082 -0.2 0.018 0.0014 0.082
InternetService 0.035 0.23 -0.024 -0.021 1 0.026 0.036 0.19 0.17 0.028
OnlineSecurity 0.2 -0.056 0.22 0.082 0.026 1 -0.076 0.046 0.032 0.22
SeniorCitizen 0.091 0.15 -0.076 -0.2 0.036 -0.076 1 0.025 0.06 -0.13
StreamingTV 0.33 0.45 0.21 0.018 0.19 0.046 0.025 1 0.44 0.14
StreamingMovies 0.34 0.43 0.22 0.0014 0.17 0.032 0.06 0.44 1 0.11
TechSupport 0.2 -0.00072 0.31 0.082 0.028 0.22 -0.13 0.14 0.11 1
tenure
MonthlyCharges
Contract
Dependents
InternetService
OnlineSecurity
SeniorCitizen
StreamingTV
StreamingMovies
TechSupport
1.0
0.8
0.6
0.4
0.2
0.0

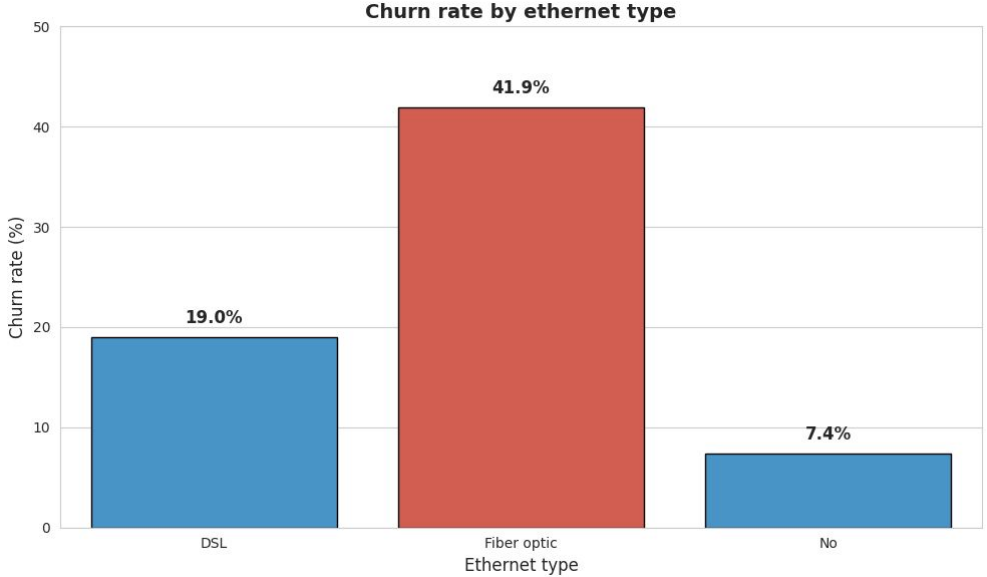
Churn rate by ethernet type
Churn rate (%)
50
40
30
20
10
0
19.0%
41.9%
7.4%
DSL
Fiber optic
No
Ethernet type

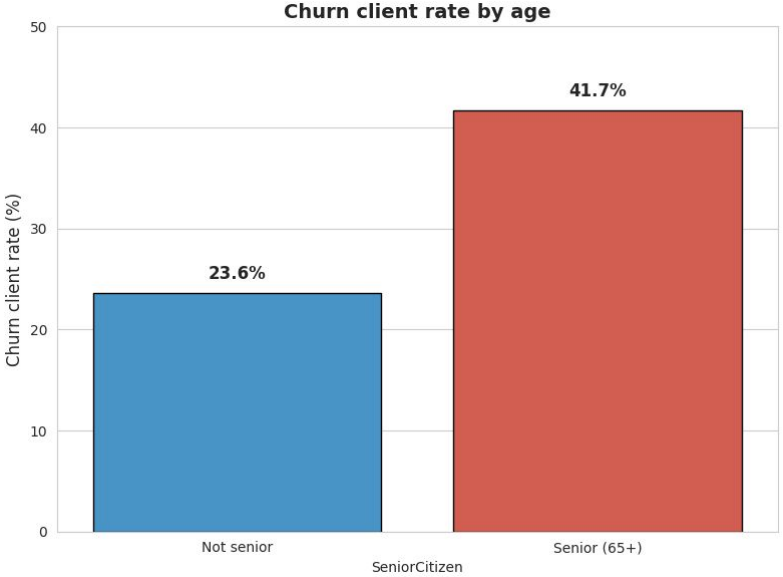
Churn client rate by age
Churn client rate (%)
50
40
30
20
10
0
23.6%
41.7%
Not senior
Senior (65+)
SeniorCitizen

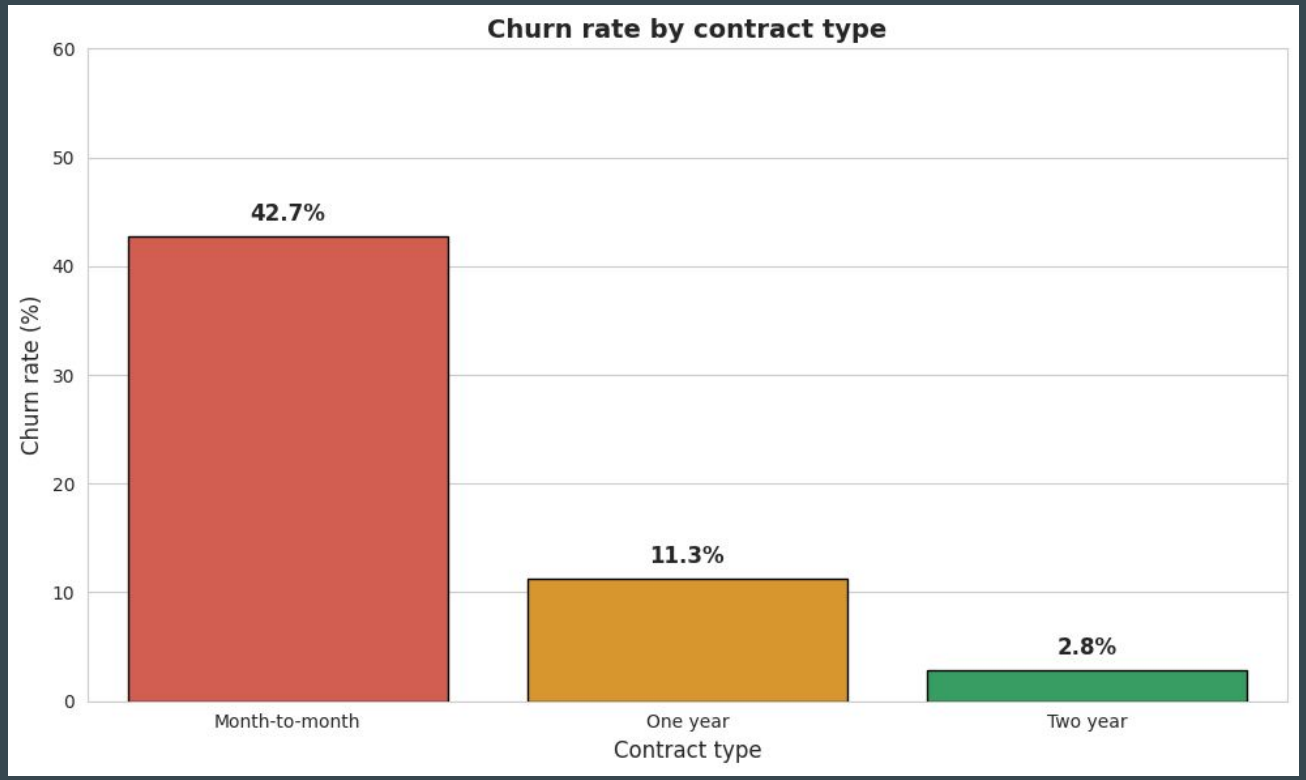
Churn rate by contract type
60
50
40
30
20
10
0
Churn rate (%)
42.7%
11.3%
2.8%
Month-to-month
One year
Two year
Contract type

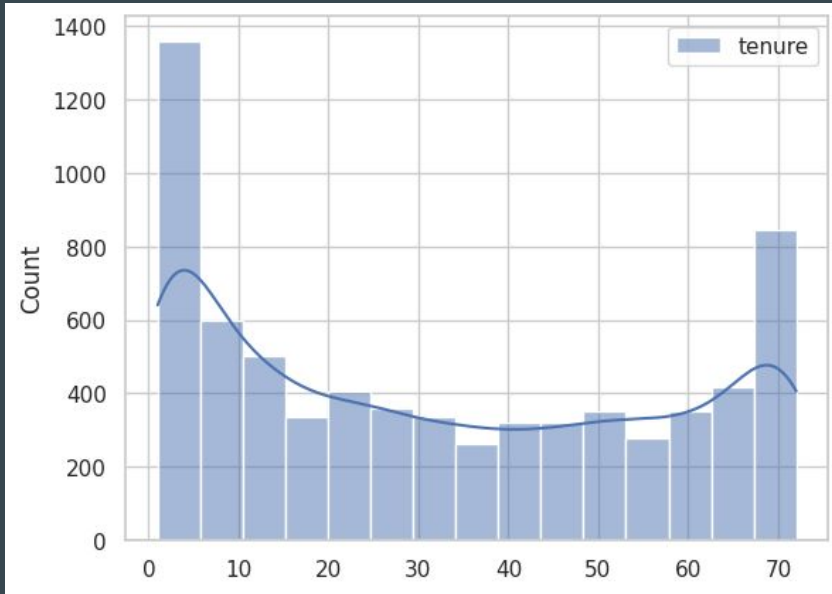
tenure
Count
1400
1200
1000
800
600
400
200
0
0
10
20
30
40
50
60
70

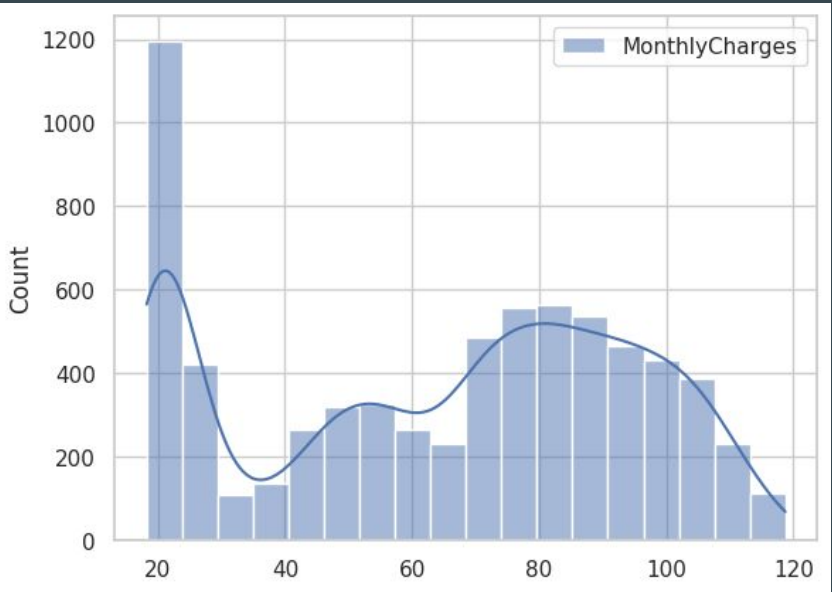
MonthlyCharges
Count
1200
1000
800
600
400
200
0
20
40
60
80
100
120

Десерт